开源 · 国产 GPU 适配 · MIT

UniVis

模型搬上国产 GPU，哪一层算错了，一眼看见。

逐层对照两次运行，指出分叉从哪一层、哪个子层开始。已在沐曦曦云 C500 完成真机验证。

MetaX 曦云 C500 真机验证 | **pip install univis** | cookiesheep.github.io/univis

只看最终输出，分不出「正常误差」和「算子写错」。

96.2%

数值栈完全正确的 bf16
与参考答案的 top-1 一致率

96.2%

第 17 层 MLP 激活函数写错的 bf16
与参考答案的 top-1 一致率

一模一样。差异藏在中间某一层里。

四步，全部在 forward hook 里完成。

不改模型、不搬 GB 级张量；两台机器各存几 MB 指纹，任何人都能在 CPU 上复核。

01

Teacher forcing

两端喂完全相同的 token，一次前向跑完，逐位置严格对齐。

02

端侧草图

每层出口投影到 64 维；投影是线性的，P(a)−P(b)=P(a−b)。

03

容差基线

以已知正常的同精度实现作为「正常误差」，不拍脑袋定阈值。

04

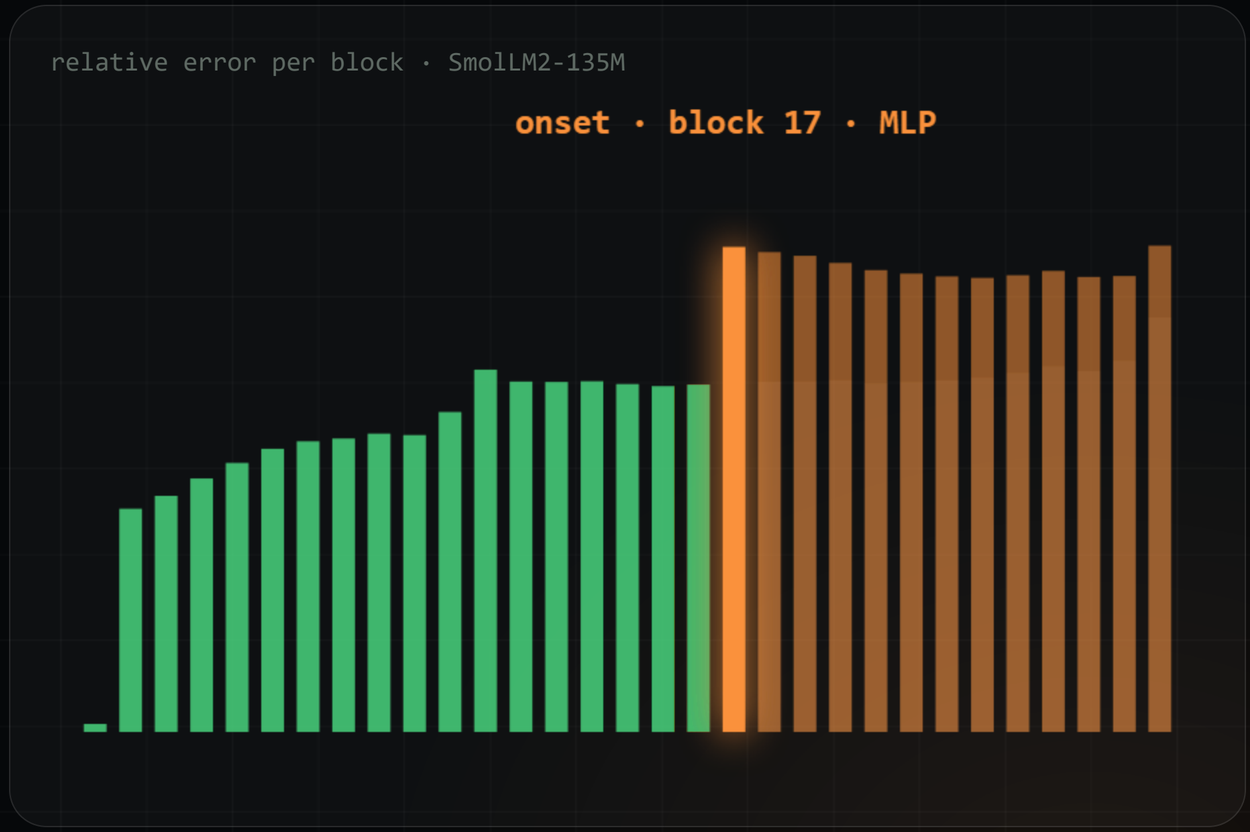
三态判定

PASS · DIVERGE（起点层 + attention / MLP）· UNKNOWN，可接入 CI。

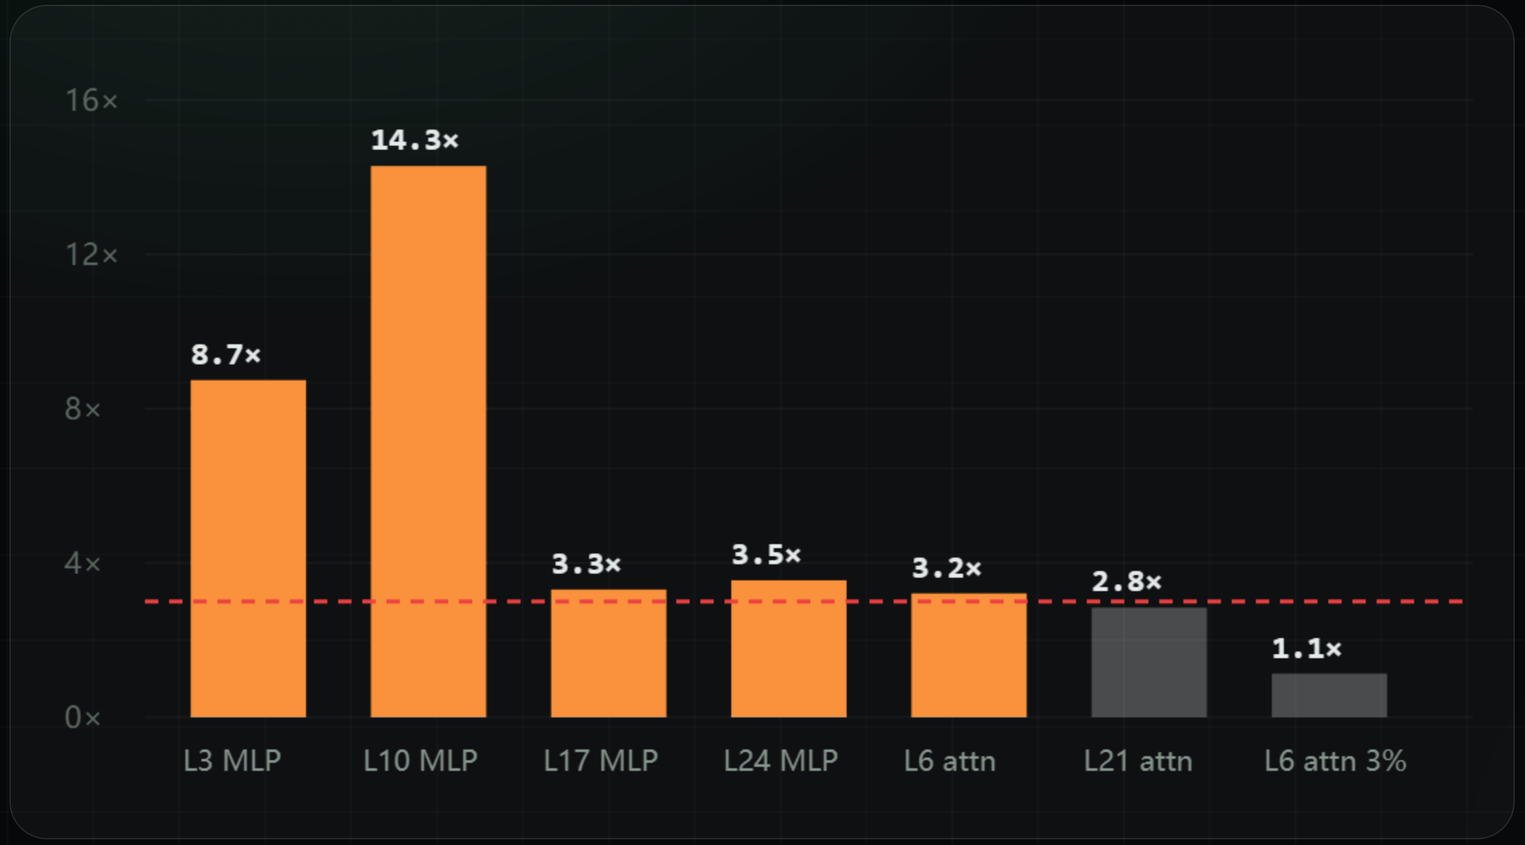
30 秒，在 CPU 上看到分叉起点。

```
$ pip install "univis[hf]"
$ univis diff demo

correct bf16 : top-1 96.2%
broken  bf16 : top-1 96.2%
DIVERGE at block 17,
MLP output (3.3x)
```



明显写错的算子，全部定位到正确的层。



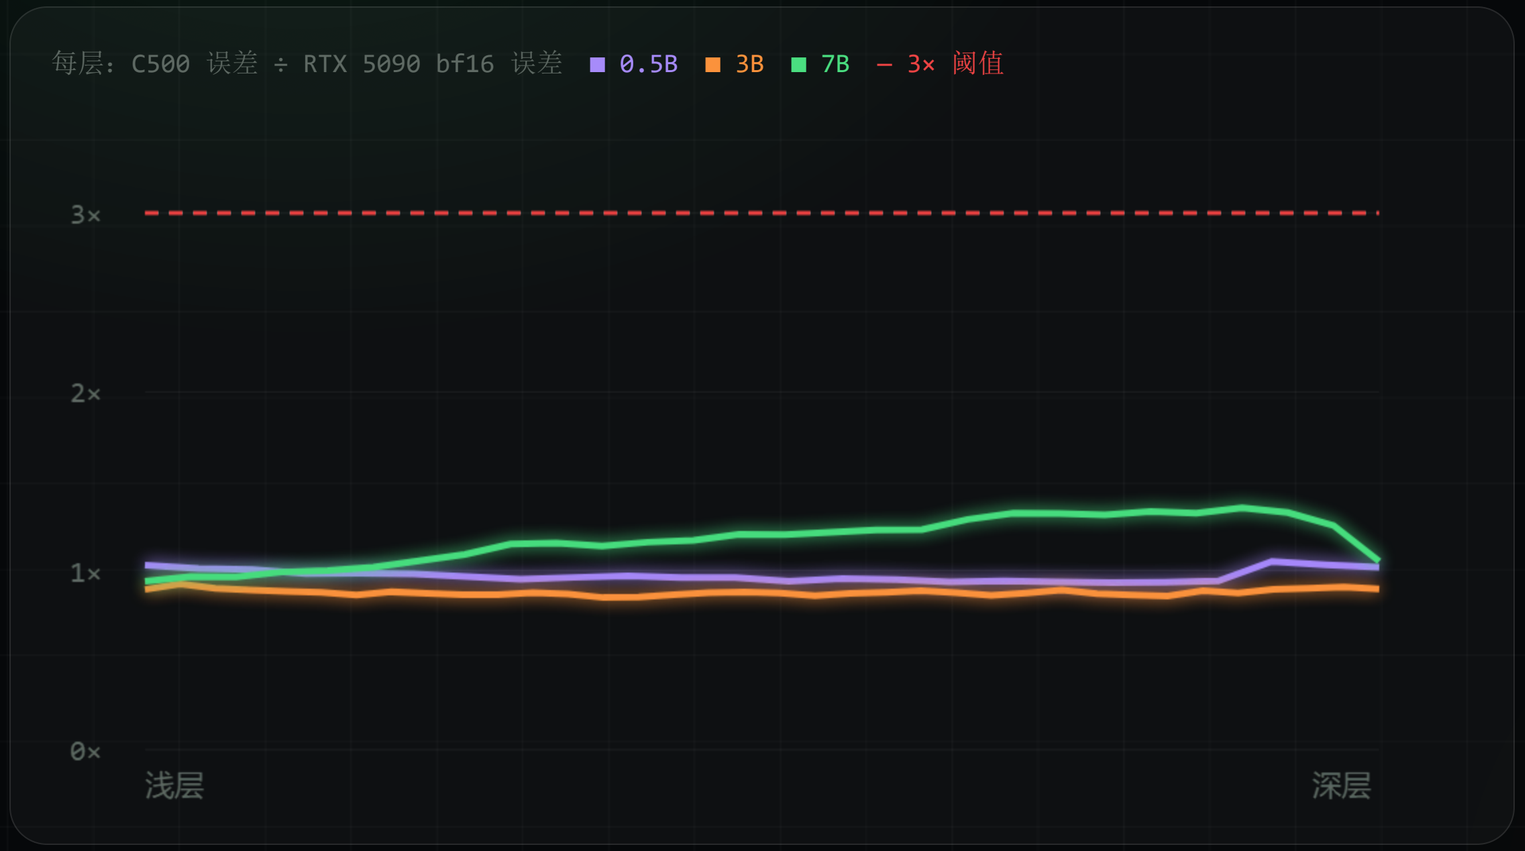
5 / 5

MLP 与 attention 故障
定位到正确的层和子层

如实标边界

3% 细微偏差会被 bf16 噪声淹没；
深层 20% 偏差为 2.84×

三个规模，每一层都在正常 bf16 误差之内。



3 / 3

Qwen2.5 0.5B / 3B / 7B 全部 PASS

≤ 1.35×

每层误差相对 NVIDIA bf16 的最大倍数

参考：RTX 5090 fp32　容差：RTX 5090 bf16　C500：MACA 3.3.0.15 · torch 2.8.0+metax3.3.0.2　结论只覆盖所测模型与软件栈

换算子不出错，默认设置要当心。

1.47×

沐曦 flash-attention：更快，精度 PASS

1024 token、3B 模型前向 109 ms → 74 ms；逐层精度仍在容差内。

290×

镜像里的「fp32」默认按 TF32 计算

相对严格 fp32 的误差。关闭：

`TORCH_ALLOW_TF32_CUBLAS_OVERRIDE=0`

一次假警报，我们用阳性对照查清了原因。

DIVERGE

3.00×

C500 eager
对 5090 sdpa 基线

PASS

1.02×

C500 eager
对 5090 eager 基线

对照

2.95×

5090 自身
eager 对 sdpa

结论写进使用契约：容差基线必须与待检端使用同一种注意力实现。

每一个结论，都能在浏览器里复核。

94
单元测试 · CI

0.7.1
PyPI 已发布

100%
真机结论附环境指纹与脚本

2
例负结果完整公开

在线体验：亲手弄坏一层，看它能不能找出来

不用安装，不用 GPU，全部真实数据

cookiesheep.github.io/univis/play.html

路线图

A · 08-19 ✓
C500 采集通路

B · 08-19 ✓
跨规模一致性

C · 10-30 ✓
逐层对照真机验证

C+ · 计划
逐层耗时 → FlagGems

D · 计划
量化前后对照

让每个模型，在国产 GPU 上算得对。

github.com/cookiesheep/univis

pip install univis

开源 · MIT