UniVis

国产 GPU 上的大模型，逐层对照

模型搬到沐曦曦云 C500 上以后，算得对不对？如果不对，从哪一层开始不对？



github.com/cookiesheep/univis · pip install univis · MetaX C500 · NVIDIA · CPU

只看最终输出，分不出「正常误差」和「算子写错」

数值栈完全正确的 bf16

96.2%

与参考答案的 top-1 一致率

第 17 层算子写错的 bf16

96.2%

与参考答案的 top-1 一致率：一模一样

把比较深入到每一层，才能看出问题从哪里开始：



绿色：在正常 bf16 误差内　　橙色： block 17 的 MLP 输出开始超出 3.3 倍

UniVis 怎么做：四步，全部在 forward hook 里完成

1

Teacher forcing

两端喂同一段 token，一次前向跑完，逐位置严格对齐

2

端侧草图

每层出口投影到 64 维，P(a)−P(b)=P(a−b)，几 MB 指纹可跨机器比对

3

容差基线

以已知正常的同精度实现与参考的误差，作为该精度的「正常误差」

4

三态判定

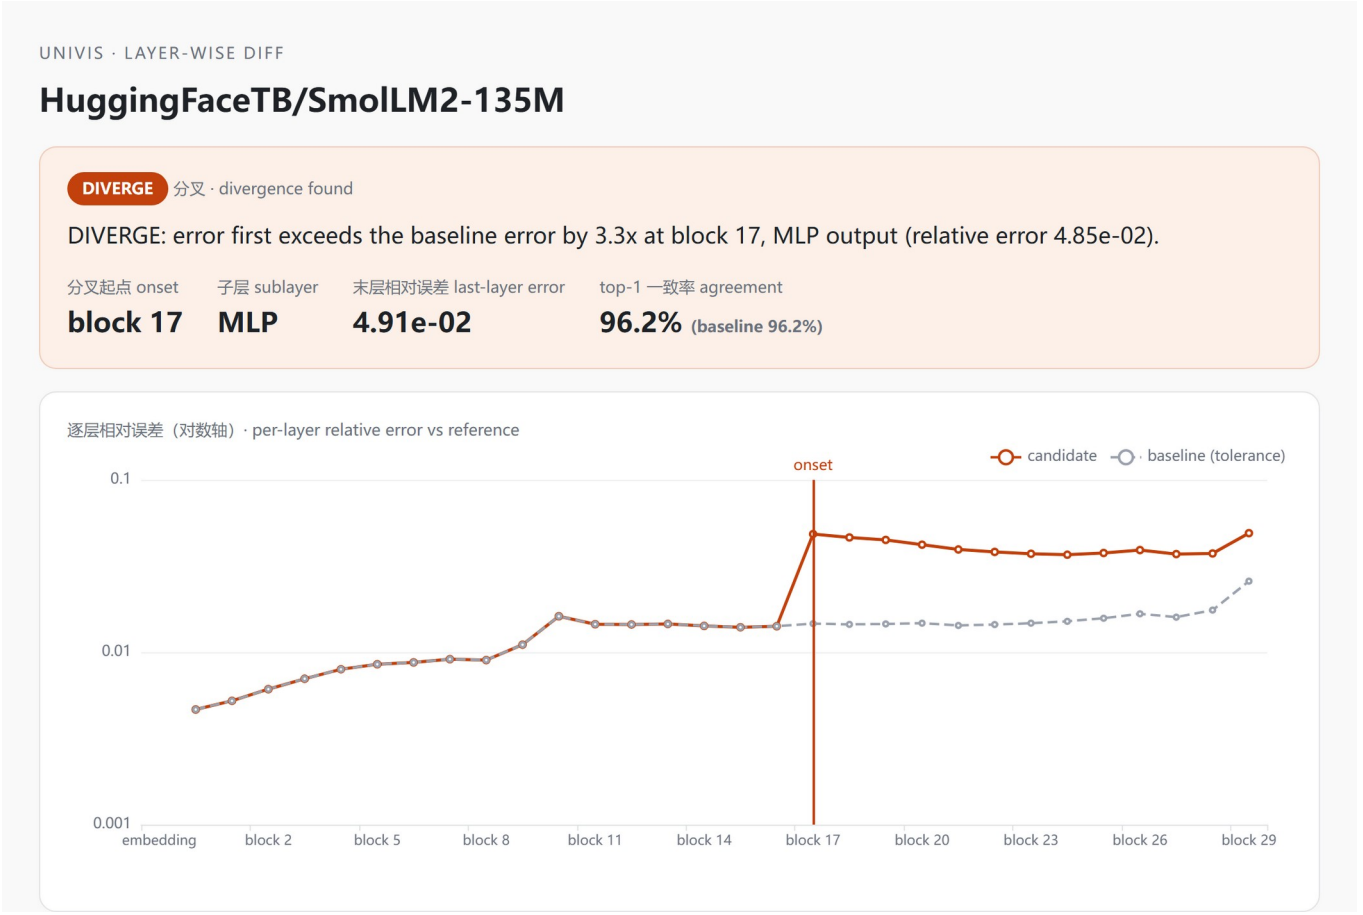
PASS / DIVERGE（起点层 + attention 或 MLP） / UNKNOWN

结果：一份自包含 HTML 报告 + 退出码（0 一致 / 1 分叉 / 3 无法判定），可直接放进 CI 做回归检查

一行命令，30 秒在 CPU 上看到结果

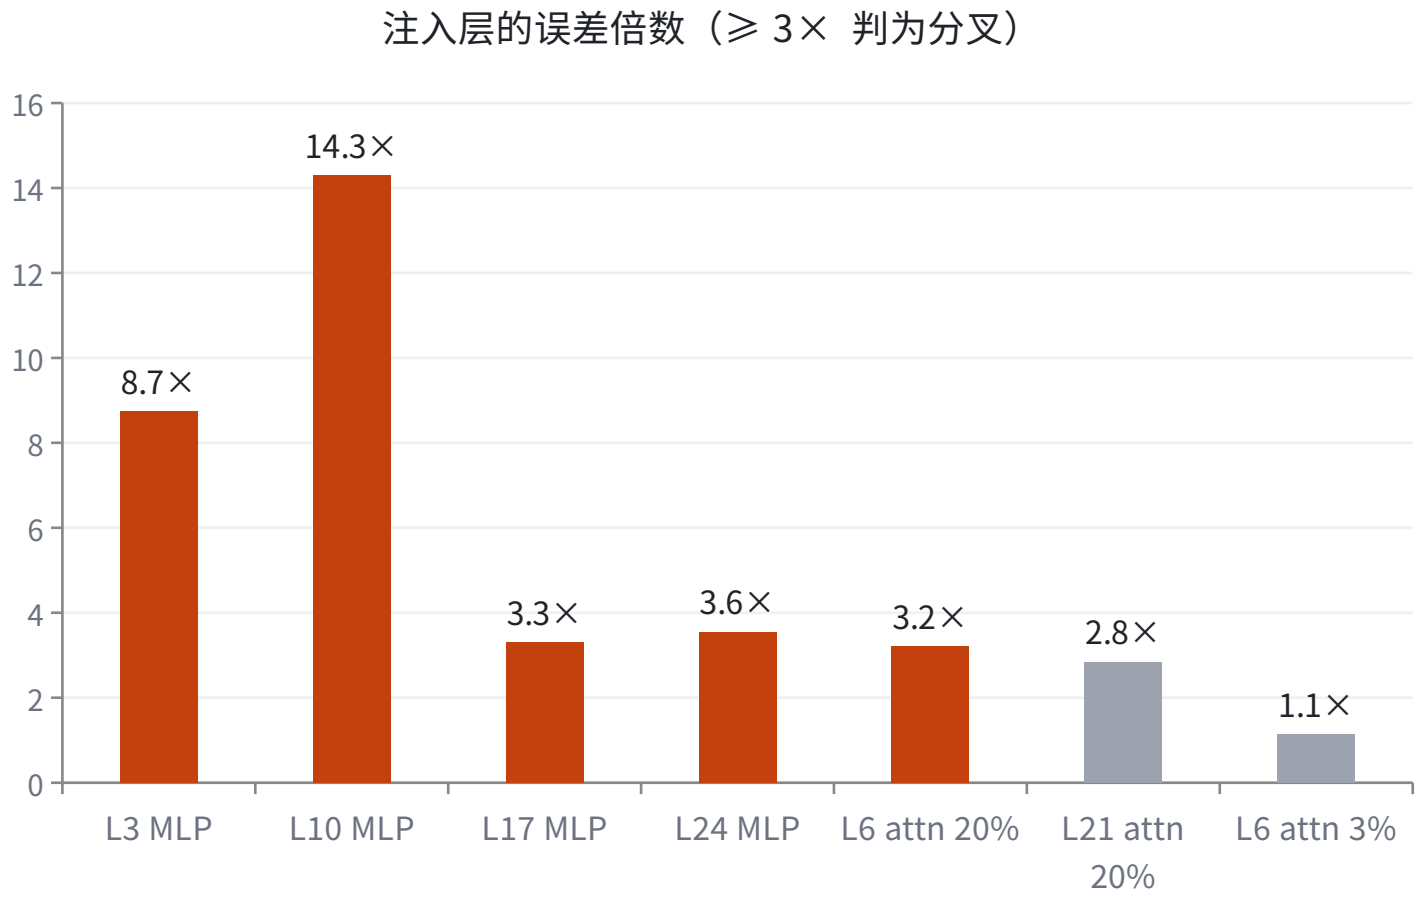
```
$ pip install "univis[hf]"
$ univis diff demo

correct bf16 : top-1 96.2%
broken  bf16 : top-1 96.2%
DIVERGE at block 17,
MLP output (3.3x)
```



自包含 HTML 报告：判定、分叉起点、子层、逐层误差曲线

故障注入：每一个明显写错的算子都被定位到正确的层



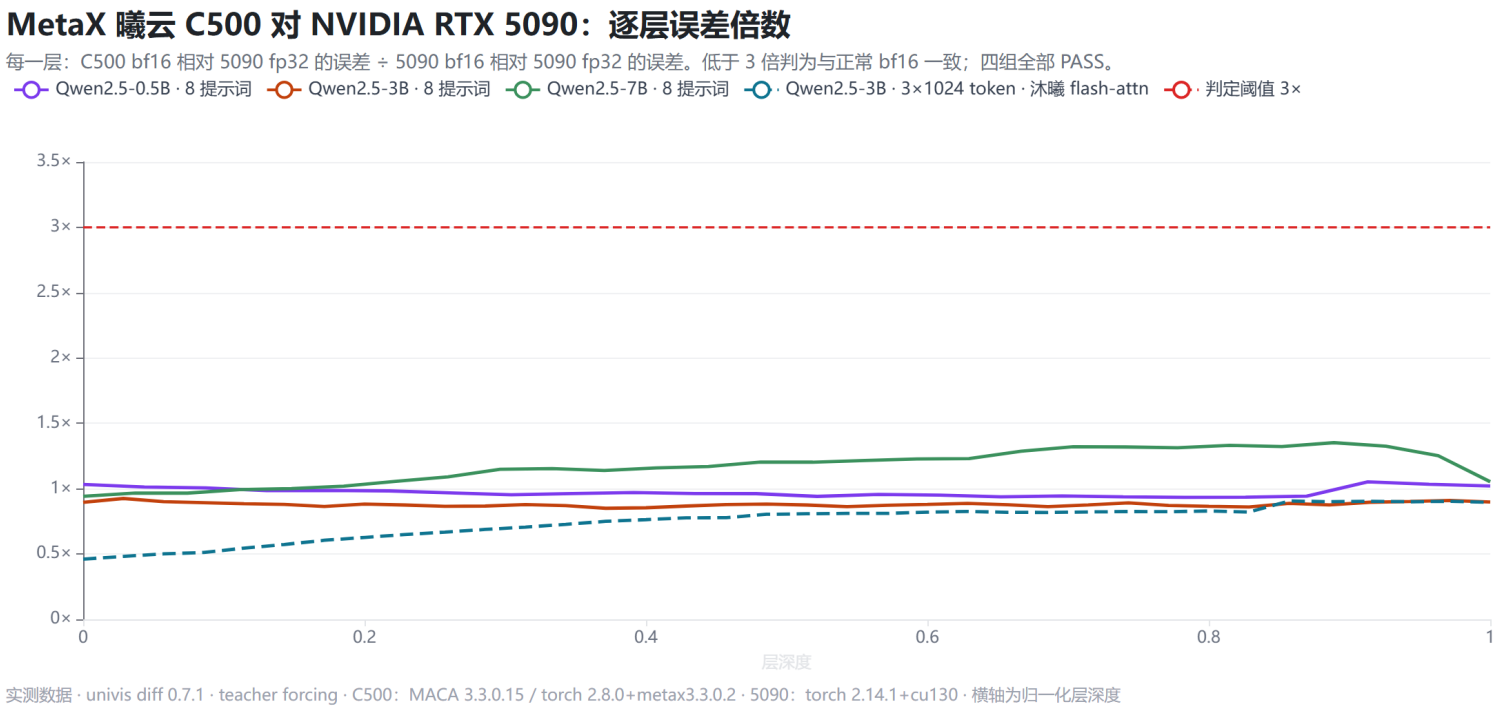
5 / 5

明显写错的算子全部定位到正确的层和子层（ attention / MLP ）

如实标出的边界

- 3% 的细微偏差被 bf16 噪声淹没
- 深层 20% 偏差为 2.84×，阈值调到 2.5 可检出

沐曦曦云 C500 真机：三个规模，每一层都在正常 bf16 误差内



3 / 3

Qwen2.5 0.5B / 3B / 7B 全部 PASS

⩽ 1.35×

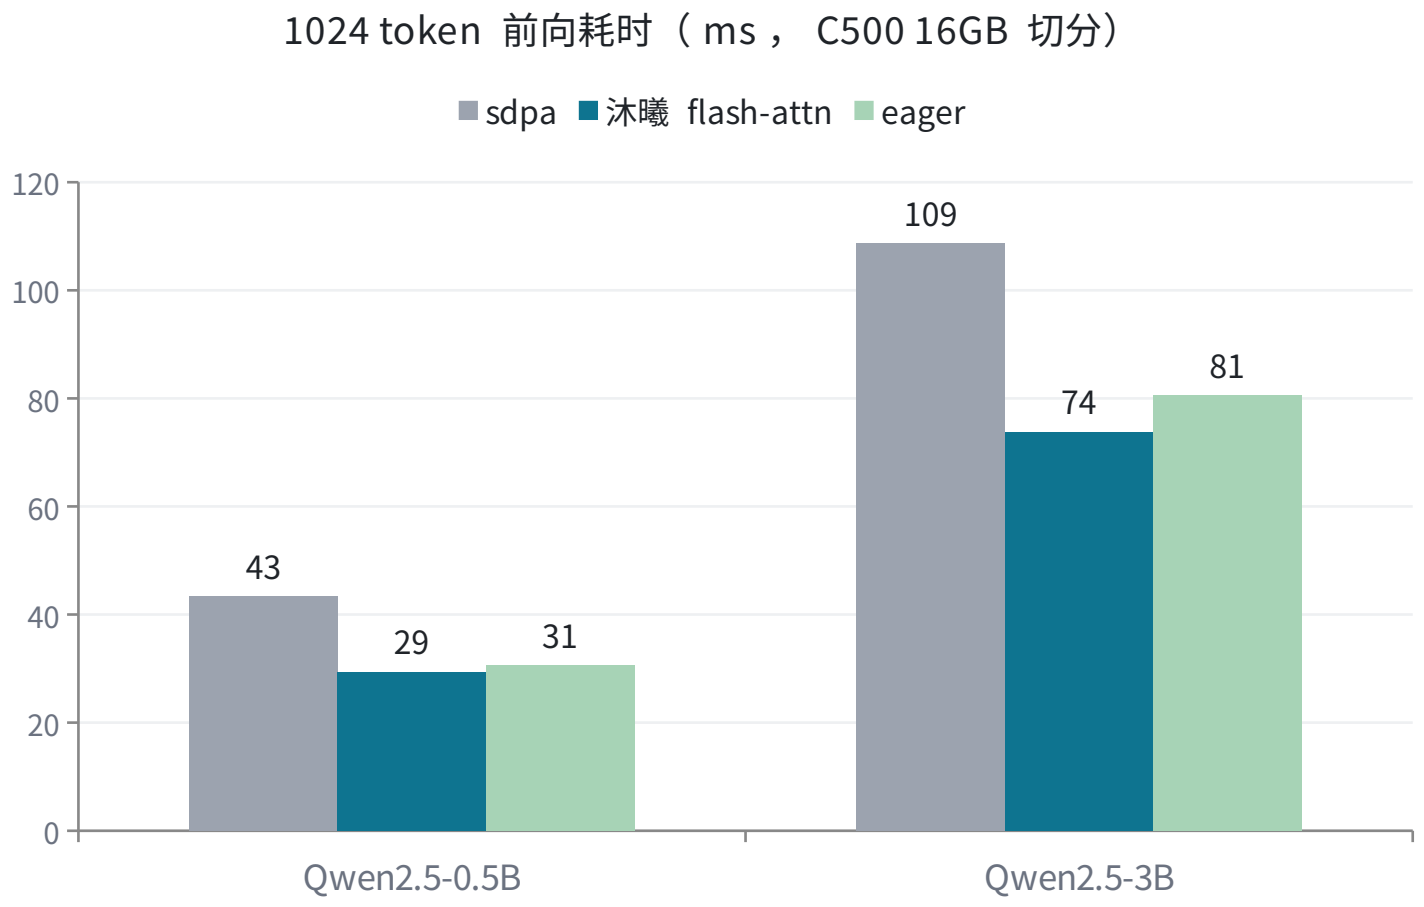
每层误差相对 NVIDIA bf16 的最大倍数

1024

token 长序列与沐曦 flash-attn 同样 PASS

C500： MACA 3.3.0.15 • torch 2.8.0+metax3.3.0.2　　RTX 5090： torch 2.14.1+cu130　　结论只覆盖所测模型、输入与软件栈

换上沐曦自带的 flash-attention：精度不变，速度快约 1.5 倍



1.47×

3B 模型： 109 ms → 74 ms

PASS

换算子后逐层精度仍在容差内（0.5B、3B， 3 × 1024 token）

发现： C500 镜像里的「 fp32 」默认按 TF32 计算

290×

默认 TF32 相对严格 fp32 的误差

- 默认（ TF32 开启）： 末层相对误差 1.66e-3
- 关闭 TF32： 5.7e-6 ， 与 CPU / NVIDIA fp32 几乎一致
- NVIDIA 上 PyTorch 默认关闭

需要严格 fp32 时

```
export TORCH_ALLOW_TF32_CUBLAS_OVERRIDE=0

torch.backends.cuda.matmul.allow_tf32 = False
torch.backends.cudnn.allow_tf32 = False
```

沐曦 MXMACA 发布说明的「已知问题」中也提到了该变量；
UniVis 把它的影响量化到了每一层

严谨性：一次假警报，我们用阳性对照查清了原因

DIVERGE

3.00×

C500 eager 对 5090 sdpa 基线

PASS

1.02×

C500 eager 对 5090 eager 基线

对照

2.95×

5090 自身： eager 对 sdpa 基线

结论写进支持契约：容差基线必须与待检端使用同一种注意力实现；未经核实的现象不下结论

无卡可审计：每个结论都能在浏览器里复核



cookiesheep.github.io/univis/play.html

94 单元测试， CI 全绿

0.7.1 PyPI 已发布： pip install univis

2 例负结果完整公开

100% 真机结论附环境指纹与脚本

路线图：从「能在 C500 上跑」到「帮别人在 C500 上跑对」

2026-08-19	2026-08-19	2026-10-30	计划	计划
A	B	C	C+	D
C500 采集通路验证	C500 与 NVIDIA 跨规模一致性	逐层对照真机验证：0.5B / 3B / 7B 全部 PASS	逐层耗时 → 换 FlagGems / mcTriton 算子 → 验证精度	量化前后逐层对照，给出建议保留高精度的层
已完成	已完成	已完成	计划	计划

让每个模型在国产 GPU 上算得对

在线体验 cookiesheep.github.io/univis/play.html
GitHub github.com/cookiesheep/univis
PyPI pip install univis

欢迎在国产 GPU 上遇到「输出和 NVIDIA 不一样」时来提 issue，我们一起用 univis diff 定位